# 系统调用追踪指令

```
# 跟踪SocketBIO程序
strace -ff -o out java SocketBIO
# 模拟客户端,连接服务器
nc localhost 9090
# 查看系统连接状态
netstat -natp
```

# IO模型

无论BIO、NIO、多路复用器,都是同步 IO 模型

#### BIO

# Java代码

```
public static void main(String[] args) {
        ServerSocket serverSocket = new ServerSocket(8090);
        System.out.println("Step1: new ServerSocket(8090)");
        while (true) {
            Socket client = serverSocket.accept();
            System.out.println("Step2: client\t" + client.getPort());
            new Thread(() -> {
                try {
                    InputStream in = client.getInputStream();
                    BufferedReader reader = new BufferedReader(new InputStreamReader(in));
                    while (true) {
                        Thread.sleep(1000);
                        System.out.println(Thread.currentThread().getName() + " readLine
data : " + reader.readLine());
                    }
                } catch (Exception e) {
                    e.printStackTrace();
                }
            }).start();
   } catch (IOException e) {
        e.printStackTrace();
    }
}
```

# 内核执行流程

• 当执行 new ServerSocket(8090), 系统内核会调用 socket, bind, listen 创建服务端socket, 绑定端口, 开启监听

```
# 创建socket, 得到 fd = 5
socket(AF_INET6, SOCK_STREAM, IPPROTO_IP) = 5
# 绑定端口
bind(5, {sa_family=AF_INET6, sin6_port=htons(8090), ....) = 0
# 开启监听
listen(5, 50) = 0
```

• 在 JDK1.4 会执行accept系统调用阻塞,等待客户端连接

```
# 阻塞,等待客户端连接
accept(5,
# 接收 端口号为46552的客户端连接,得到客户端连接 fd = 6
accept(5, {sa_family=AF_INET6, sin6_port=htons(46552), ....) = 6
# 创建子线程,处理客户端读写
clone(child_stack=0x7fc475b09fb0,
flags=CLONE_VM|CLONE_FS|CLONE_FILES|CLONE_SIGHAND|CLONE_THREAD|CLONE_SYSVSEM|CLONE_SET
TLS|CLONE_PARENT_SETTID|CLONE_CHILD_CLEARTID, parent_tidptr=0x7fc475b0a9d0,
tls=0x7fc475b0a700, child_tidptr=0x7fc475b0a9d0) = 23019
# 在子进程out.23019文件中,调用recv阻塞读取客户端数据
recv(6,
# 当客户端有数据输入
recv(6, "test\n", 8192, 0, NULL, NULL) = 5
write(1, "Thread-0 readLine data: test", 29) = 29
```

• 使用JDK1.8 执行 accept 系统调用, 会使用 poll 系统调用阻塞, 等待客户端连接

```
# 使用poll多路复用器阻塞,等待客户端连接
poll([{fd=5, events=POLLIN|POLLERR}], 1, -1
# 当有客户端连接进来后,接收到 POLLIN 事件
poll([{fd=5, events=POLLIN|POLLERR}], 1, -1) = 1 ([{fd=5, revents=POLLIN}])
# 接收 端口号为46552的客户端连接,得到客户端连接 fd = 6
accept(5, {sa_family=AF_INET6, sin6_port=htons(46552), ....) = 6
# 通过clone创建子线程,处理客户端读写
clone(child_stack=0x7fc475b09fb0,
flags=CLONE_VM|CLONE_FS|CLONE_FILES|CLONE_SIGHAND|CLONE_THREAD|CLONE_SYSVSEM|CLONE_SET
TLS|CLONE_PARENT_SETTID|CLONE_CHILD_CLEARTID, parent_tidptr=0x7fc475b0a9d0,
tls=0x7fc475b0a700, child_tidptr=0x7fc475b0a9d0) = 23019
# 在子进程out.23019文件中,调用recv阻塞读取客户端数据
recvfrom(6,
# 当客户端有数据输入
recvfrom(6, "test\n", 8192, 0, NULL, NULL) = 5
write(1, "Thread-0 readLine data : test", 29) = 29
```

# 伪代码

```
socket() = 5;
bind(5, 8090);
listen(5, 50);
while(true){
    // 阻塞,接收客户端连接
    accept(5,) = fd;
    // 创建线程,处理客户端数据
    clone() = while(true){
        // 阻塞,接收客户端数据
        recv(fd,);
    }
}
```

#### 总结

可以看到,真正的BIO是在jdk1.4之前,之后使用poll多路复用器来获取连接

- 概念: BIO, 对于每个客户端连接,都会创建一个线程来处理客户端数据。一连接,一线程
- 缺点:
  - 大量连接接入时,需要创建很多线程,浪费系统资源
  - o CPU在给线程分配资源的时候,需要频繁的进行内核空间与用户空间的切换,造成大量切换的开销
  - 阻塞,建立连接阻塞,读取数据阻塞
- 解决方案:采用非阻塞方式,于是就有了NIO的诞生

#### NIO

### Java代码

```
public static void main(String[] args) {
   LinkedList<SocketChannel> clients = new LinkedList<>();
   try {
       ServerSocketChannel channel = ServerSocketChannel.open();
       channel.bind(new InetSocketAddress(9090));
       channel.configureBlocking(false);
       while (true) {
           Thread.sleep(2000);
            SocketChannel socketChannel = channel.accept();
            if (socketChannel == null) {
                System.out.println("socketChannel is null...");
            } else {
                socketChannel.configureBlocking(false);
                int port = socketChannel.socket().getPort();
                System.out.println("Client port : " + port);
                clients.add(socketChannel);
            }
            ByteBuffer byteBuffer = ByteBuffer.allocateDirect(4096);
            for (SocketChannel sc : clients) {
                int num = sc.read(byteBuffer);
```

```
if (num > 0) {
          byteBuffer.flip();
          byte[] a = new byte[byteBuffer.limit()];
          byteBuffer.get(a);
          String b = new String(a);
          System.out.println(sc.socket().getPort() + ":" + b);
          byteBuffer.clear();
        }
    }
}
catch (Exception e) {
    e.printStackTrace();
}
```

### 内核执行流程

• 创建socket、绑定端口、开启监听

```
socket(AF_INET6, SOCK_STREAM, IPPROTO_IP) = 6
bind(6, {sa_family=AF_INET6, sin6_port=htons(9090), ...) = 0
listen(6, 50) = 0
```

• 设置获取客户端连接非阻塞

```
fcnt1(6, F_SETFL, O_RDWR|O_NONBLOCK) = 0
```

• 执行channel.accept, 进行系统调用, 不阻塞, 获取结果为null, 往下继续执行

```
# 当没有客户端连接时,返回 -1
accept(6, 0x7fe3181045c0, [28]) = -1 EAGAIN (资源暂时不可用)
write(1, "socketChannel is null...", 24) = 24
```

• 当有客户端连接进来后,得到客户端连接 fd = 7

```
accept(6, {sa_family=AF_INET6, sin6_port=htons(58400), ...) = 7
# 设置客户端读取数据非阻塞
fcntl(7, F_SETFL, O_RDWR|O_NONBLOCK) = 0
```

• 执行read读取客户端数据,进行系统调用,不阻塞,没有数据返回-1

```
# <u>当客户端没有数据发送</u>, <u>返回</u> -1
read(7, 0x7fe31810aa70, 4096) = -1 EAGAIN(资源暂时不可用)
```

• 当有客户端数据发送时

```
# 读取到数据
read(7, "hello\n", 4096) = 6
```

#### 伪代码

#### 总结

- 概念: NIO,通过一个线程来创建客户连接,读写客户端数据;在Java层面NIO是指New IO,在操作系统层面NIO是指Non Blocking IO
- 优点:面对大量连接,避免了创建大量线程的问题,通过一个线程处理N个连接以及读写
- 缺点:在有大量连接的情况下,若只有1个客户端有数据,每次循环必须向内核发送一次 read 系统调用,造成很多系统调用都是无效的。
- 解决方案:通过IO多路复用器,将所有fd传递给内核,由系统来检测哪些fd是可读状态,遍历可读写的fd,减少read系统调用次数

# 多路复用器

服务端采用单线程,通过 select 、poll、epoll 等系统调用传递 fd 列表到内核,内核遍历有事件的 fd 进行 accept、recv 等操作

IO 多路复用是一种同步 IO 模型,实现一个线程可以监视多个 fd ,一旦某个 fd 就绪,就能通知应用程序进行相对应的读写操作;没有 fd 就绪时就会阻塞程序,交出 CPU

多路是指多个网络连接,复用指的是一个线程

# select, poll

• select: 单个进程打开的FD有限,通过 FD\_SETSIZE 设置,默认1024

• poll: 没有 FD 限制

**优点**:通过一次系统调用,把 fds 传递给内核,获取可执行 fd 的数量;在内核中进行遍历,减少了系统调用的次数

#### 缺点:

- 每次调用 select, poll 都需要把 fd 集合传递给内核空间,从用户态拷贝到内核态,这个在 fd 很多时开销很大
- 每次 select, poll 都需要重新遍历全量的 fd

## epoll

• 通过在内核开辟空间,使用红黑树存储 fd , 避免 fd 集合从用户态到内核态的多次拷贝

### Java代码

```
static ServerSocketChannel server = null;
static Selector selector = null;
public static void main(String[] args) {
    initServer();
    System.out.println("服务器启动了....");
    try {
        while (true) {
            Set<SelectionKey> selectionKeys = selector.keys();
            System.out.println("keys.size = " + selectionKeys.size());
            while (selector.select() > 0) {
                // 遍历有状态的key
                Set<SelectionKey> keys = selector.selectedKeys();
                Iterator<SelectionKey> iterator = keys.iterator();
                while (iterator.hasNext()) {
                    SelectionKey selectionKey = iterator.next();
                    iterator.remove();
                    if (selectionKey.isAcceptable()) {
                        handleAccept(selectionKey);
                    } else if (selectionKey.isReadable()) {
                        handleRead(selectionKey);
                    }
                }
            }
        }
    } catch (IOException e) {
        e.printStackTrace();
    }
}
public static void initServer() {
    try {
        server = ServerSocketChannel.open();
        server.bind(new InetSocketAddress(9090));
        server.configureBlocking(false);
        selector = Selector.open();
        server.register(selector, SelectionKey.OP_ACCEPT);
    } catch (Exception e) {
        e.printStackTrace();
   }
}
```

```
public static void handleAccept(SelectionKey key) {
    try {
        ServerSocketChannel serverSocketChannel = (ServerSocketChannel) key.channel();
        SocketChannel client = serverSocketChannel.accept();
        client.configureBlocking(false);
        ByteBuffer byteBuffer = ByteBuffer.allocateDirect(4098);
        client.register(selector, SelectionKey.OP_READ, byteBuffer);
        System.out.println("client address : " + client.getRemoteAddress());
   } catch (Exception e) {
        e.printStackTrace();
   }
}
public static void handleRead(SelectionKey key) {
    SocketChannel socketChannel = (SocketChannel) key.channel();
    ByteBuffer byteBuffer = (ByteBuffer) key.attachment();
    byteBuffer.clear();
    int read = 0;
    try {
        while (true) {
            read = socketChannel.read(byteBuffer);
            if (read > 0) {
                byteBuffer.flip();
                byte[] a = new byte[byteBuffer.limit()];
                byteBuffer.get(a);
                String b = new String(a);
                System.out.println("read data : " + b);
                byteBuffer.clear();
            }
        }
    } catch (Exception e) {
        e.printStackTrace();
    }
}
```

## 内核执行流程

• 创建socket、绑定端口、开启监听

```
socket(AF_INET6, SOCK_STREAM, IPPROTO_IP) = 6
bind(6, {sa_family=AF_INET6, sin6_port=htons(9090), ....) = 0
listen(6, 50) = 0
```

• 在内核开辟存储空间,存储 fd,得到内核空间的文件描述符 = 9

```
# 在内核开辟内存空间
epoll_create(256) = 9
```

• 往内核空间中添加socket连接

```
# 往内核空间9中添加 fd=6 的socket
epoll_ctl(9, EPOLL_CTL_ADD, 6, {EPOLLIN, {u32=6, u64=140651589009414}}) = 0
```

• 通过 epoll wait 系统调用,在超时时间内阻塞等待客户端连接

```
epoll_wait(9,
```

• 当有客户端连接, epoll\_wait检测到有客户端连接

```
# epoll_wait 返回1, 发现 fd=6 上有事件触发
epoll_wait(9, [{EPOLLIN, {u32=6, u64=140651589009414}}], 4096, -1) = 1
# 通过accept系统调用, 在 socket=6 上, 创建客户端连接 fd = 10
accept(6, {sa_family=AF_INET6, sin6_port=htons(58420), ....) = 10
# 将客户端连接 fd 添加到 系统内核中
epoll_ctl(9, EPOLL_CTL_ADD, 10, {EPOLLIN, {u32=10, u64=140651589009418}}) = 0
# 阻塞, 等待fd上有事件发生
epoll_wait(9,
```

• 客户端又数据写入

```
# epoll_wait 返回1, 发现 fd=10 上有事件触发
epoll_wait(9, [{EPOLLIN, {u32=10, u64=140651589009418}}], 4096, -1) = 1
# 读取数据
read(10, "hello epoll\n", 4098) = 12
# 打印数据
write(1, "read data: hello epoll\n", 24) = 24
# 不阻塞, 继续循环读取, 客户端数据,
read(10, 0x7fec0c120520, 4098) = -1 EAGAIN(资源暂时不可用)
read(10, 0x7fec0c120520, 4098) = -1 EAGAIN(资源暂时不可用)
```

### 伪代码

```
// 创建socket, 绑定端口, 开启监听
socket() = 6
bind(6, 9090)
listen(6, 50)
fcnt1(6, F_SETFL, O_RDWR|O_NONBLOCK);
// 开辟内核空间
epoll_create(256) = 9
// 将socket添加到内核
epoll_ctl(9, EPOLL_CTL_ADD, 6, \{EPOLLIN, \{u32=6, u64=140651589009414\}\}) = 0
epoll_wait(9, // 阻塞, 当有 fd 事件发生, 返回结果大于0
// epoll_wait(9, [{EPOLLIN, {u32=6, u64=140651589009414}}], 4096, -1) = 1
// epoll_wait(9, [{EPOLLIN, {u32=10, u64=140651589009418}}], 4096, -1) = 1
while(epoll_wait(9) > 0) {
   if (key.isAcceptable()) {
       // 创建客户端连接 fd
       accept(6, {sa_family=AF_INET6, sin6_port=htons(58420), ...) = 10
       // 设置客户端非阻塞
```

#### 总结

- 通过 epoll\_create, epoll\_ctl, epoll\_wait 三个系统调用实现
- epoll\_create: 在内核开辟一块空间,存储文件描述符 fd,返回一个内核空间的描述符epfd
- epoll\_ctl: 内核空间操作
  - EPOLL\_CTL\_ADD: 往内核空间中注册一个fd
  - EPOLL\_CTL\_MOD:修改内核空间中注册的fd
  - EPOLL\_CTL\_DEL: 从内核空间中删除注册的fd
- lepoll\_wait: 在超时时间内阻塞等待IO事件发生, 当有事件发生, 则返回发生事件的 fd 数量

每当fd就绪,系统注册回调函数就会被调用,将就绪的fd放到readyList中

# 附录一、案例追踪

### **Redis**

```
# 在内核开辟空间,得到空间fd=5
epoll_create(1024) = 5
# 创建socket, fd=7
socket(AF_INET, SOCK_STREAM, IPPROTO_TCP) = 7
# 在fd=7上绑定6379端口
bind(7, {sa\_family=AF\_INET, sin\_port=htons(6379), sin\_addr=inet\_addr("0.0.0.0")}, 16) = 0
# 开启监听
listen(7, 511) = 0
# 将fd=7添加到内核空间
epoll_ctl(5, EPOLL_CTL_ADD, 7, {EPOLLIN, \{u32=7, u64=7\}\}} = 0
# 非阻塞,等待事件触发
epoll_wait(5, [], 10128, 0)
epoll_wait(5, [], 10128, 100)
# 有客户端连接接入
epoll_wait(5, [{EPOLLIN, \{u32=7, u64=7\}\}], 10128, 100) = 1
# 创建客户端连接,得到fd=8
accept(7, {sa_family=AF_INET, sin_port=htons(36250), sin_addr=inet_addr("127.0.0.1")},
[128 -> 16]) = 8
# 将fd=8添加到内核空间
```

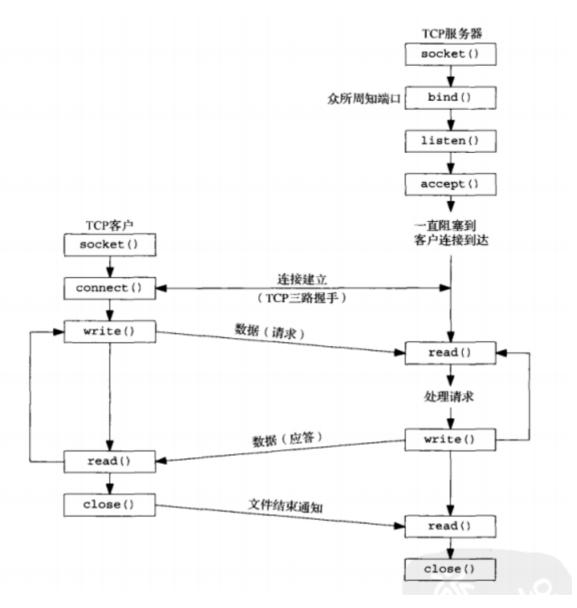
```
epoll_ctl(5, EPOLL_CTL_ADD, 8, {EPOLLIN, {u32=8, u64=8}}) = 0
# 有数据写入
epoll_wait(5, [{EPOLLIN, {u32=8, u64=8}}], 10128, 15) = 1
# 非阻塞, 等待事件触发
epoll_wait(5, [], 10128, 1) = 0
epoll_wait(5, [], 10128, 100) = 0
# 客户端fd=8有数据写入, epoll_wait监听到事件发生, 执行read
epoll_wait(5, [{EPOLLIN, {u32=8, u64=8}}], 10128, 100) = 1
read(8, "*2\r\n$3\r\nget\r\n$4\r\nname\r\n", 16384) = 23
```

# 附录二、系统调用函数

```
// 创建一个socket文件描述符, sockfd
int socket(int domain, int type, int protocol);
// 为socket绑定一个端口
int bind(int sockfd, const struct sockaddr *addr, socklen_t addrlen);
// 在socket上开启监听
int listen(int sockfd, int backlog);
// 在socket上接收客户端连接
int accept(int sockfd, struct sockaddr *addr, socklen_t *addrlen);
// 读取 socket fd 上的数据, 返回数据长度
ssize_t recv(int sockfd, void *buf, size_t len, int flags);
ssize_t recvfrom(int sockfd, void *buf, size_t len, int flags,
                      struct sockaddr *src_addr, socklen_t *addrlen);
// 读取 fd 上的数据,返回数据长度
ssize_t read(int fd, void *buf, size_t count);
// 在内核开辟空间,返回内核空间文件描述符,epfd
int epoll_create(int size);
// op=add:在内核空间中注册目标fd的事件
// op=mod: 修改内核空间中注册的目标fd事件
// op=del: 删除内核空间中的fd
int epoll_ctl(int epfd, int op, int fd, struct epoll_event *event);
// 等待内核空间fd有事件发生,可设置超时时间,timeout=-1阻塞,timeout=0 直接返回
int epoll_wait(int epfd, struct epoll_event *events, int maxevents, int timeout);
```

# 附录三、系统调用追踪日志

## 系统调用流程



# BIO主线程

# BIO子线程

```
set robust list(0x7fc475b0a9e0, 24)
                                        = 23019
gettid()
rt sigprocmask(SIG BLOCK, NULL, [QUIT], 8) = 0
rt sigprocmask(SIG UNBLOCK, [HUP INT ILL BUS FPE SEGV USR2 TERM], NUL
rt sigprocmask(SIG BLOCK, [QUIT], NULL, 8) = 0
futex(0x7fc48800a554, FUTEX WAKE OP PRIVATE, 1, 1, 0x7fc48800a550, FU
futex(0x7fc48800a528, FUTEX WAKE PRIVATE, 1) = 1
mmap(0x7fc440000000, 67108864, PROT NONE, MAP PRIVATE|MAP ANONYMOUS|M
mprotect(0x7fc440000000, 135168, PROT READ|PROT WRITE) = 0
sched getaffinity(23019, 32, [0, 1])
sched getaffinity(23019, 32, [0, 1])
mmap(0x7fc475a0a000, 12288, PROT READ|PROT WRITE, MAP PRIVATE|MAP FIX
mprotect(0x7fc475a0a000, 12288, PROT NONE) = 0
lseek(3, 29961031, SEEK SET)
                                        = 29961031
read(3, "PK\3\4\n\0\0\10\0\0\26\273kP\340\0161\236E\3\0\0E\3\0\0\27\0
lseek(3, 29961084, SEEK SET)
                                        = 29961084
read(3, "\312\376\272\276\0\0004\0-\1\0\24()Ljava/lang/Object"...,
lseek(3, 29962814, SEEK SET)
                                        = 29962814
read(3, "PK\3\4\n\0\0\10\0\0\30\273kP\262\217^g\257\r\0\0\257\r\0\0 \
lseek(3, 29962876, SEEK SET)
                                        = 29962876
read(3, "\312\376\272\276\0\0\0004\0\240\10\0\6\10\0\7\10\0\26\10\0\3
futex(0x7fc4880daa54, FUTEX WAIT BITSET PRIVATE, 1, {tv sec=20353, tv
futex(0x7fc4880daa28, FUTEX WAKE PRIVATE, 1) = 0
recvfrom(6, "test\n", 8192, 0, NULL, NULL) = 5
ioctl(6, FIONREAD, [0])
write(1, "Thread-0 readLine data : test", 29) = 29
write(1, "\n", 1)
futex(0x7fc4880daa54, FUTEX WAIT BITSET PRIVATE, 1, {tv sec=22990, tv
futex(0x7fc4880daa28, FUTEX WAKE PRIVATE, 1) = 0
recvfrom(6,
```

#### NIO

#### **EPOLL**